



Context Ensemble for Tabular Foundation Models

周奕博

2026年7月24日

研究问题与核心思路

核心问题

TabICL/TabPFN 的预测不仅取决于测试样本本身，还会受到 in-context examples 的影响。不同 context 中的类别比例、局部邻域和边界样本可能改变模型判断。

核心思想

不修改模型参数，在推理阶段构造多组 context；使用同一个 TabICL 分别预测，形成 context ensemble，并通过门控机制判断是否修正原始预测。

两类测试场景

No-shift：测试集与训练集的类别分布接近。Shift：测试集与训练集的类别分布存在明显差异。

No-Shift 场景：Context Ensemble 修正局部样本

大多数样本：原始 TabICL 预测稳定，不需要修改。

少数样本：位于类别边界，容易受到 context 中参考样本的影响。

Context 如何影响预测？

附近样本不同：如果 context 中相似的 A 类样本更多，模型更可能预测为 A；如果 B 类样本更多，则可能预测为 B。

参考样本不同：只参考各类别的典型样本时，模型可能倾向于 A；加入类别边界附近的样本后，模型可能判断为 B。

同一个测试样本，在不同 context 下可能得到不同的预测结果。

1. 为每个测试样本构造多组 Context

$$S_i = \left\{ S_i^{knn}, S_i^{proto}, S_i^{bd/bracket}, S_i^{sub}, S_i^{clean} \right\}$$

这些 context 从不同角度为模型提供参考：

S_i^{knn} ：看局部近邻（回归：观察近邻的目标值）

S_i^{proto} ：看类别代表样本（回归：看不同目标值区间的代表样本）

$S_i^{bd/bracket}$ ：看类别边界两侧样本（回归：看基线预测值上下两侧的样本）

S_i^{sub} ：看不同特征子空间中的邻居（回归相同）

S_i^{clean} ：看标签更纯净的邻居（回归：看剔除异常点后的干净邻域）

其中，分类任务使用 S_i^{bd} ，回归任务使用对应的 $S_i^{bracket}$ 。

■ 单个 Context 如何推动正确修正？

某个特殊 context 可以率先发现原始预测错误，并提出候选预测 $\hat{y}_i^{(r)}$ 。其他 context 不需要完全同意，只负责进行安全检查：

Baseline 不确定： 原始预测 margin 较低， $u_i \uparrow$

没有强烈反对： 其他 context 未高置信预测相反结果， c_i 不低

局部标签支持： 邻近训练样本支持候选类别， $s_i \uparrow$

因此，样本级更新强度增大：

$$\alpha_i = \alpha_{\max} u_i c_i s_i$$

最终预测向 context ensemble 的方向移动：

$$p_i^{\text{final}}(y) = (1 - \alpha_i) p_i^0(y) + \alpha_i \bar{p}_i(y)$$

如何排除有偏 Context 的错误修正?

如果某个 context 被局部噪声误导并提出错误预测，系统会通过三类风险信号压低其影响：

与其他 context 分歧较大： 多数 context 不支持甚至高置信反对该修正， $c_i \downarrow$

缺乏局部标签支持： 邻近训练样本不支持候选类别， $s_i \downarrow$

与高置信 Baseline 冲突： 原始 TabICL 判断稳定，缺少修改必要性， $u_i \downarrow$

因此，样本级更新强度接近于 0：

$$\alpha_i = \alpha_{\max} u_i c_i s_i \approx 0$$

最终预测自动退回原始 TabICL：

$$p_i^{\text{final}}(y) = (1 - \alpha_i) p_i^0(y) + \alpha_i \bar{p}_i(y) \approx p_i^0(y)$$

同时，有偏 context 的可靠性权重也会被压低： $w_i^{(r)} \downarrow$

2. 同一个 TabICL 在不同 Context 下预测

对每个 context, 同一个 TabICL 产生预测:

$$p_i^{(r)}(y) = P_{\theta}(y \mid x_i, S_i^{(r)})$$

其中:

- r 表示第 r 个 context
- 模型参数 θ 不变
- 变化的是参考样本集合 $S_i^{(r)}$

因此这是: 同一个模型 + 不同的 context。

而不是传统的 multiple models ensemble。

3.Context Ensemble: 把多个预测合起来

不是简单平均，而是按可靠性加权。加权集成预测：

$$\bar{p}_i(y) = \sum_r w_i^{(r)} p_i^{(r)}(y)$$

权重满足：

$$\sum_r w_i^{(r)} = 1$$

可靠的 context 通常满足：

- 与其他 context 投票一致
- 预测概率分布稳定
- 候选类别有局部标签支持
- 不与基线预测产生高风险冲突

4. 如何判断 Context 是否可靠？——分类

三个核心信号

投票一致性：不同 context 是否支持同一个类别

$$v_i = \frac{1}{R} \sum_{r=1}^R \mathbf{1} \left[\arg \max_y p_i^{(r)}(y) = \hat{y}_i^{ctx} \right]$$

Context 分歧：不同 context 的预测概率是否接近

$$d_i = \frac{1}{R} \sum_{r=1}^R \left\| p_i^{(r)} - \bar{p}_i \right\|_2^2$$

局部支持差：候选类别是否得到更多近邻支持

$$\ell_i = \pi_i^{loc}(\hat{y}_i^{ctx}) - \pi_i^{loc}(\hat{y}_i^0)$$

投票越一致、分歧越小、局部支持越强，context evidence 越可靠。

4. 如何判断 Context 是否可靠？——回归

三个核心信号

预测一致性：某个 context 的预测是否接近共识

$$c_i^{(r)} = \exp \left(-\frac{|\hat{y}_i^{(r)} - m_i|}{s_i^{local} + \epsilon} \right)$$

Context 分歧：不同 context 的预测值是否集中

$$D_i = \frac{\text{MAD}(\hat{y}_i^{(1)}, \dots, \hat{y}_i^{(R)})}{s_i^{local} + \epsilon}$$

局部目标值支持：预测值是否符合局部标签分布

$$\ell_i^{(r)} = \exp \left(-\frac{|\hat{y}_i^{(r)} - m_i^{local}|}{s_i^{local} + \epsilon} \right)$$

预测越接近共识、整体分歧越小、局部目标值支持越强，该 context 越可靠。

其中：

m_i ：多个 context 预测值的中位数；

m_i^{local} ：局部训练样本目标值的中位数；

s_i^{local} ：局部目标值的变化尺度；

MAD：多个预测值的中位绝对偏差。

权重 $w_i^{(r)}$ 由哪些参数构成

每个 context r 对样本 i 的可靠性由以下信号决定：

$$\phi_i^{(r)} = [1, v_i^{(r)}, \ell_i^{(r)}, d_i^{(r)}, \Delta c_i^{(r)}, g_i^{(r)}]$$

- $v_i^{(r)}$: **投票一致性**, 表示第 r 个 context 的预测类别与其他 context 的一致程度。
- $\ell_i^{(r)}$: **局部标签支持**, 表示相似邻居中有多少样本支持该 context 给出的类别。
- $d_i^{(r)}$: **预测分布分散程度**, 预测越分散, 说明该 context 越不确定, 权重应越低。
- $\Delta c_i^{(r)}$: **相对置信度提升**, $\Delta c_i^{(r)} = \max_y p_i^{(r)}(y) - \max_y p_i^0(y)$

表示该 context 相对于原始 TabICL 的置信度提升。

- $g_i^{(r)}$: **高风险冲突**, 若某个 context 强行改变原始预测, 但局部证据不足, 则该值增大, 权重应降低。

权重的计算

于是定义 context 的可靠性得分：

$$z_i^{(r)} = \beta_0 + \beta_v v_i^{(r)} + \beta_\ell \ell_i^{(r)} - \beta_d d_i^{(r)} + \beta_c \Delta c_i^{(r)} - \beta_g g_i^{(r)}$$

其中需要学习的参数为：

$$\beta = [\beta_0, \beta_v, \beta_\ell, \beta_d, \beta_c, \beta_g]$$

再通过 softmax 将可靠性得分归一化为权重：

$$w_i^{(r)} = \frac{\exp(z_i^{(r)})}{\sum_{j=1}^R \exp(z_i^{(j)})}$$

总损失函数

总损失可以写为：

$$\mathcal{L}(\beta) = \mathcal{L}_{ce} + \lambda_{\text{rank}} \mathcal{L}_{\text{rank}} + \lambda_{\text{trust}} \mathcal{L}_{\text{trust}} + \lambda_{\text{reg}} \|\beta\|_2^2$$

其中：

- $\mathcal{L}_{ce}$ ：分类损失，保证融合预测具有较高的分类准确率；
- $\mathcal{L}_{\text{rank}}$ ：排序损失，鼓励正样本得分高于负样本，以维持 ROC-AUC；
- $\mathcal{L}_{\text{trust}}$ ：信任区域损失，限制融合预测过度偏离原始 TabICL 预测；
- $\lambda_{\text{reg}} \|\beta\|_2^2$ ：正则化项，防止参数过大并降低过拟合风险。

其中， λ_{rank} 、 λ_{trust} 和 λ_{reg} 分别控制各损失项的相对强度。

6.保守融合：不直接覆盖原预测

即使通过门控，也只是小幅修正

最终预测：

$$p_i^{final}(y) = (1 - \alpha_i)p_i^0(y) + \alpha_i\bar{p}_i(y)$$

其中， α_i 是更新强度。

- 若证据强， $\alpha_i > 0$
- 若证据弱， $\alpha_i \approx 0$
- 若门控不通过， $\alpha_i = 0$

当 $\alpha_i = 0$ 时：

$$p_i^{final}(y) = p_i^0(y)$$

更新强度的决定机制

其中 $\alpha_i \in [0, \alpha_{\max}]$ 是样本级更新强度。它由基线不确定性、上下文共识和局部支持共同决定：

$$\alpha_i = \alpha_{\max} \cdot u_i \cdot c_i \cdot s_i$$

这里 u_i 衡量基线预测是否处于低 margin 区域，

c_i 衡量上下文预测是否一致，

s_i 衡量候选类别是否得到局部标签结构支持。

若基线本身高置信，或上下文之间存在明显分歧，则 α_i 接近 0，最终预测退化为原始 TabICL 输出。

实验设计

数据集设置

- 分类任务采用 CC18 的 72 个分类数据集，评价指标为 Accuracy 和 ROC-AUC。
- 回归任务采用 CTR23 的 35 个回归数据集，评价指标为 R^2 、NMAE 和 NRMSE。

五种操纵类型

- **Shortcut** : 修改与目标最相关的特征，制造具有误导性的特征—目标关系。
- **Boundary** : 修改决策边界或目标分位点附近的样本，使其偏向错误方向。
- **AUCband / Rankband** : 修改特征中间区域的样本，破坏分类分数或回归目标的排序关系。
- **Local** : 在局部样本区域内同时修改重要特征和目标关系。
- **Mixed** : 将样本分组，并分别施加上述四种操纵。

TabPFN v2+context ensemble

Problem	rho	Datasets	Base Acc	Method Acc	Delta Acc	Base AUC	Method AUC	Delta AUC
original	0	72	0.7875	0.7942	+0.0066	0.8908	0.8956	+0.0048
shortcut	20	72	0.6707	0.6731	+0.0024	0.8107	0.8120	+0.0013
	50	72	0.4929	0.5816	+0.0887	0.6659	0.7098	+0.0439
	80	72	0.3202	0.4843	+0.1641	0.4995	0.6246	+0.1251
	100	72	0.2015	0.4009	+0.1994	0.3721	0.5534	+0.1813
boundary	20	72	0.6821	0.6833	+0.0012	0.8254	0.8267	+0.0013
	50	72	0.5133	0.5881	+0.0748	0.7041	0.7348	+0.0307
	80	72	0.3342	0.4800	+0.1458	0.5380	0.6396	+0.1016
	100	72	0.2252	0.4173	+0.1922	0.4070	0.5716	+0.1647
aucband	20	72	0.6912	0.6933	+0.0021	0.8285	0.8293	+0.0008
	50	72	0.5419	0.6031	+0.0612	0.7148	0.7396	+0.0247
	80	72	0.3971	0.5239	+0.1267	0.5842	0.6610	+0.0768
	100	72	0.3001	0.4740	+0.1738	0.4865	0.6189	+0.1324
local	20	72	0.6719	0.6746	+0.0027	0.8122	0.8135	+0.0014
	50	72	0.4964	0.5822	+0.0858	0.6697	0.7118	+0.0421
	80	72	0.3249	0.4851	+0.1603	0.5052	0.6267	+0.1215
	100	72	0.2082	0.4004	+0.1922	0.3777	0.5490	+0.1713
mixed	20	72	0.6771	0.6797	+0.0026	0.8179	0.8193	+0.0014
	50	72	0.5082	0.5863	+0.0780	0.6841	0.7178	+0.0337
	80	72	0.3456	0.4889	+0.1433	0.5264	0.6311	+0.1047
	100	72	0.2361	0.4243	+0.1882	0.4062	0.5703	+0.1641

TablCL v2+context ensemble

Problem	rho	Datasets	Base Acc	Method Acc	Delta Acc	Base AUC	Method AUC	Delta AUC
original	0	72	0.8037	0.8047	+0.0010	0.9007	0.9007	+0.0000
shortcut	20	72	0.6872	0.6884	+0.0012	0.8381	0.8384	+0.0003
	50	72	0.5115	0.5975	+0.0860	0.7088	0.7366	+0.0278
	80	72	0.3464	0.4985	+0.1521	0.5495	0.6462	+0.0967
	100	72	0.2240	0.4212	+0.1973	0.4121	0.5684	+0.1563
boundary	20	72	0.7013	0.7026	+0.0013	0.8474	0.8475	+0.0002
	50	72	0.5321	0.6119	+0.0798	0.7370	0.7594	+0.0224
	80	72	0.3497	0.5061	+0.1564	0.5706	0.6603	+0.0897
	100	72	0.2331	0.4251	+0.1921	0.4202	0.5709	+0.1508
aucband	20	72	0.7101	0.7108	+0.0008	0.8542	0.8544	+0.0003
	50	72	0.5679	0.6102	+0.0423	0.7542	0.7615	+0.0073
	80	72	0.4331	0.5339	+0.1008	0.6304	0.6806	+0.0503
	100	72	0.3349	0.4763	+0.1415	0.5260	0.6082	+0.0821
local	20	72	0.6882	0.6893	+0.0012	0.8396	0.8399	+0.0003
	50	72	0.5146	0.5995	+0.0849	0.7111	0.7382	+0.0271
	80	72	0.3502	0.4979	+0.1478	0.5511	0.6456	+0.0945
	100	72	0.2296	0.4205	+0.1909	0.4128	0.5679	+0.1551
mixed	20	72	0.6941	0.6951	+0.0010	0.8417	0.8420	+0.0003
	50	72	0.5271	0.6022	+0.0751	0.7201	0.7426	+0.0225
	80	72	0.3694	0.5043	+0.1350	0.5680	0.6485	+0.0805
	100	72	0.2559	0.4353	+0.1795	0.4381	0.5746	+0.1365

TabPFN v2+context ensemble

Problem	rho	Base R ²	Method R ²	ΔR^2	Base NMAE	Method NMAE	$\Delta NMAE$	Base NRMSE	Method NRMSE	$\Delta NRMSE$
original	0	0.7191	0.7191	+0.0000	0.2563	0.2563	+0.0000	0.4990	0.4990	+0.0000
shortcut	20	0.5370	0.6583	+0.1213	0.3363	0.2899	+0.0464	0.6782	0.5781	+0.1002
	50	0.2938	0.6402	+0.3465	0.4677	0.3126	+0.1551	0.8444	0.5970	+0.2474
	80	0.1380	0.6722	+0.5342	0.5808	0.2970	+0.2838	0.9470	0.5606	+0.3864
	100	0.3339	0.7003	+0.3664	0.5087	0.2834	+0.2253	0.7954	0.5303	+0.2651
boundary	20	0.3648	0.6737	+0.3089	0.5142	0.3202	+0.1940	0.8194	0.5726	+0.2468
	50	-1.2617	0.6918	+1.9535	1.0509	0.3116	+0.7393	1.4469	0.5434	+0.9035
	80	-3.0166	0.7072	+3.7237	1.5902	0.2960	+1.2942	1.9528	0.5233	+1.4295
	100	-5.1022	0.6999	+5.8022	2.1011	0.3049	+1.7962	2.4071	0.5361	+1.8710
rankband	20	-0.0211	0.5234	+0.5445	0.5604	0.3888	+0.1716	1.0330	0.7133	+0.3197
	50	-1.5383	0.6871	+2.1254	1.0852	0.3794	+0.7058	1.5853	0.6269	+0.9584
	80	-3.3560	0.7053	+4.0613	1.6569	0.2966	+1.3603	2.0466	0.5264	+1.5202
	100	-4.7134	0.7009	+5.4143	2.0266	0.3027	+1.7239	2.3329	0.5344	+1.7985
local	20	0.6865	0.7130	+0.0264	0.2853	0.2682	+0.0171	0.5406	0.5128	+0.0278
	50	0.6220	0.6976	+0.0756	0.3345	0.2879	+0.0466	0.6014	0.5361	+0.0652
	80	0.3526	0.7062	+0.3536	0.4716	0.2869	+0.1847	0.7667	0.5244	+0.2423
	100	-1.4842	0.7103	+2.1945	1.2512	0.2834	+0.9677	1.5608	0.5170	+1.0438
mixed	20	0.5615	0.7049	+0.1434	0.4259	0.2903	+0.1356	0.6895	0.5292	+0.1603
	50	-0.2178	0.7081	+0.9259	0.8595	0.2802	+0.5794	1.1333	0.5160	+0.6172
	80	-3.0679	0.7050	+3.7729	1.6782	0.2899	+1.3883	1.9967	0.5266	+1.4701
	100	-6.4758	0.6975	+7.1734	2.3564	0.3106	+2.0458	2.6581	0.5419	+2.1162

TablCL v2+context ensemble

Problem	rho	Base R ²	Method R ²	ΔR^2	Base NMAE	Method NMAE	$\Delta NMAE$	Base NRMSE	Method NRMSE	$\Delta NRMSE$
original	0	0.7568	0.7568	+0.0000	0.2370	0.2370	+0.0000	0.4509	0.4509	+0.0000
shortcut	20	0.5707	0.6969	+0.1262	0.3117	0.2699	+0.0418	0.6417	0.5358	+0.1059
	50	0.3543	0.6845	+0.3302	0.4389	0.2918	+0.1472	0.8014	0.5545	+0.2469
	80	0.1904	0.7141	+0.5237	0.5555	0.2786	+0.2768	0.9138	0.5198	+0.3941
	100	-1.2719	0.7437	+2.0156	0.8250	0.2741	+0.5509	0.9967	0.4765	+0.5202
boundary	20	0.3369	0.6661	+0.3291	0.4971	0.3234	+0.1737	0.8240	0.5803	+0.2437
	50	-1.0942	0.7304	+1.8246	1.0175	0.2972	+0.7203	1.4006	0.5031	+0.8975
	80	-2.8416	0.7441	+3.5857	1.5624	0.2830	+1.2794	1.9029	0.4813	+1.4216
	100	-5.1315	0.7414	+5.8730	2.1099	0.2914	+1.8185	2.4106	0.4902	+1.9204
rankband	20	0.0352	0.5541	+0.5189	0.5426	0.3743	+0.1683	0.9978	0.6843	+0.3135
	50	-1.3771	0.6186	+1.9957	1.0390	0.3730	+0.6660	1.5275	0.6036	+0.9238
	80	-3.2137	0.7440	+3.9577	1.6228	0.2820	+1.3408	2.0098	0.4823	+1.5275
	100	-4.7371	0.7422	+5.4793	2.0342	0.2890	+1.7453	2.3357	0.4884	+1.8474
local	20	0.7085	0.7401	+0.0316	0.2737	0.2558	+0.0179	0.5163	0.4823	+0.0340
	50	0.6361	0.7243	+0.0882	0.3315	0.2785	+0.6531	0.5849	0.5056	+0.0793
	80	0.3977	0.7330	+0.3354	0.4602	0.2792	+0.1810	0.7460	0.5013	+0.2447
	100	-0.9177	0.7469	+1.6646	1.0625	0.2656	+0.7969	1.3960	0.4728	+0.9232
mixed	20	0.6580	0.7471	+0.0891	0.3828	0.2664	+0.1163	0.5977	0.4726	+0.1251
	50	-0.0092	0.7511	+0.7603	0.8104	0.2603	+0.5501	1.0449	0.4645	+0.5804
	80	-2.0705	0.7482	+2.8187	1.4616	0.2687	+1.1929	1.7478	0.4745	+1.2733
	100	-5.9418	0.7398	+6.6815	2.2404	0.2926	+1.9478	2.5628	0.4943	+2.0686



Shift 场景

- **测试集分布发生变化**

测试集与训练集的标签分布不再一致。

(分类：类别比例发生变化；回归：目标值分布发生变化)

- **Context 会影响模型判断**

Context 中的标签分布可能使模型偏向某些类别或目标值区间。

1. 构造 Prior-Intervention Context

对同一个测试样本，主动构造具有不同标签分布的 context:

$$S_i^{prior} = \left\{ S_i^{train}, S_i^{bal}, S_i^{unif}, S_i^{tilt} \right\}$$

- S_i^{train} : 保持训练集原有的标签分布
- S_i^{bal} : 平衡不同类别或目标值区间
- S_i^{unif} : 在可能的先验分布中进行均匀采样
- S_i^{tilt} : 刻意偏向某个类别或目标值区间

分类任务改变 context 中的类别比例；回归任务改变 context 中不同目标值区间的样本比例。

提取去先验证据

对于多个 Prior Context:

$$\log p_i^{(r)}(y) \approx e_i(y) + \beta_i \log \pi_i^{(r)}(y)$$

先估计样本对先验的敏感程度 β_i ，然后从每组预测中减去先验项:

$$\tilde{e}_i(y) = \frac{1}{R} \sum_{r=1}^R \left[\log p_i^{(r)}(y) - \beta_i \log \pi_i^{(r)}(y) \right]$$

此时， $\tilde{e}_i(y)$ 只是不同类别的**去先验证据得分**，还不是概率。需要通过 softmax 进行归一化:

$$\tilde{p}_i(y) = \frac{\exp(\tilde{e}_i(y))}{\sum_c \exp(\tilde{e}_i(c))}$$

得到的 $\tilde{p}_i(y)$ 表示:

TabPFN v2+context ensemble

Strength	Datasets	Base Acc	Method Acc	Delta Acc	Base AUC	Method AUC	Delta AUC
0.2	72	0.7833	0.7944	+0.0111	0.8901	0.8957	+0.0056
0.5	72	0.7799	0.7941	+0.0141	0.8892	0.8956	+0.0064
0.8	72	0.7759	0.7942	+0.0182	0.8874	0.8956	+0.0082
1	72	0.7717	0.7907	+0.0190	0.8844	0.8952	+0.0108
2	72	0.7584	0.7877	+0.0293	0.8722	0.8942	+0.0220
4	72	0.7267	0.7847	+0.0581	0.8391	0.8916	+0.0525

TabICL v2+context ensemble

Strength	Datasets	Base Acc	Method Acc	Delta Acc	Base AUC	Method AUC	Delta AUC
0.2	72	0.7863	0.7921	+0.0058	0.8935	0.8961	+0.0025
0.5	72	0.7656	0.7857	+0.0201	0.8749	0.8930	+0.0181
0.8	72	0.7565	0.7805	+0.0240	0.8578	0.8895	+0.0317
1	72	0.7457	0.7724	+0.0267	0.8380	0.8814	+0.0434
2	72	0.7150	0.7587	+0.0437	0.8016	0.8630	+0.0614
4	72	0.6678	0.7354	+0.0676	0.7558	0.8240	+0.0681

TabPFN v2+context ensemble

Strength	Measured shift	Base R^2	Method R^2	ΔR^2	Base NMAE	Method NMAE	Δ NMAE	Base NRMSE	Method NRMSE	Δ NRMSE
0	0.0000	0.7191	0.7191	+0.0000	0.2563	0.2563	+0.0000	0.4990	0.4990	+0.0000
0.2	0.0956	0.7202	0.7247	+0.0045	0.2556	0.2546	+0.0010	0.4990	0.4950	+0.0039
0.5	0.2487	0.7147	0.7243	+0.0096	0.2608	0.2556	+0.0053	0.5035	0.4954	+0.0081
0.8	0.3902	0.7130	0.7240	+0.0110	0.2655	0.2565	+0.0090	0.5062	0.4967	+0.0095
1	0.4867	0.6971	0.7234	+0.0263	0.2739	0.2592	+0.0147	0.5141	0.4952	+0.0190
2	0.8848	0.6413	0.7214	+0.0801	0.3102	0.2638	+0.0464	0.5573	0.5001	+0.0572
4	1.3845	0.3626	0.7028	+0.3402	0.4763	0.2892	+0.1871	0.7582	0.5337	+0.2245

TablCL v2+context ensemble

Strength	Measured shift	Base R ²	Method R ²	ΔR^2	Base NMAE	Method NMAE	$\Delta NMAE$	Base NRMSE	Method NRMSE	$\Delta NRMSE$
0	0.0000	0.7568	0.7568	+0.0000	0.2370	0.2370	+0.0000	0.4509	0.4509	+0.0000
0.2	0.0956	0.7534	0.7557	+0.0023	0.2395	0.2379	+0.0016	0.4534	0.4515	+0.0019
0.5	0.2487	0.7512	0.7570	+0.0058	0.2459	0.2400	+0.0059	0.4563	0.4508	+0.0054
0.8	0.3902	0.7413	0.7557	+0.0144	0.2534	0.2422	+0.0113	0.4629	0.4515	+0.0115
1	0.4867	0.7355	0.7551	+0.0196	0.2594	0.2429	+0.0165	0.4684	0.4521	+0.0163
2	0.8848	0.6905	0.7514	+0.0609	0.2933	0.2495	+0.0438	0.5077	0.4590	+0.0486
4	1.3845	0.4900	0.7425	+0.2525	0.4059	0.2622	+0.1437	0.6592	0.4791	+0.1801